UNIVERSIDAD AUTÓNOMA DE CHILE • PROGRAMACIÓN AVANZADA

Proyecto Integrador: Crecimiento de Vehículos Eléctricos

Informe de Avance 2: Diagnóstico, Limpieza, Tratamiento de Nulos y Transformación

Integrantes: Pablo Uribe, Dhante Torres, Maximiliano Tapia

Docente: Alex Flores Fuentealba

Fecha de entrega: 03/11/2026

Repositorio: github.com/pablo1jz/vehiculos-electricos-avance1/tree/main

1. Diagnóstico Inicial de Calidad del Dataset

El dataset cargado (`electric-car-sales.csv`) contiene las series temporales de ventas de vehículos eléctricos por entidad y año entre 2010 y 2025. El diagnóstico automatizado arrojó las siguientes características estructurales:

- **Dimensiones iniciales:** 823 filas y 4 columnas.
- **Valores nulos:** 16 registros nulos concentrados en la columna `code` (asociados a la entidad agregada *Rest of World*).
- **Registros duplicados:** 0 filas duplicadas.
- **Inconsistencias de dominio:** Presencia de 4 valores negativos en ventas asociadas a la categoría *Rest of World* (ej. -49,752 en 2022).
- **Mezcla de niveles geográficos:** Agregación conjunta de países independientes con entidades regionales completas (*World*, *Europe*, *European Union (27)*).

2. Estrategia y Tratamiento de Valores Faltantes y Anomalías

Para garantizar la integridad y el rigor estadístico sin perder observaciones valiosas, se definieron y aplicaron las siguientes reglas de negocio:

Variable	Problema Detectado	Tratamiento Aplicado	Justificación
`code`	16 nulos (Rest of World)	Imputación con valor DESC	Permite preservar la categoría sin corromper el análisis por falta de código ISO.
`electric_cars_sold`	4 valores negativos (< 0)	Filtrado condicional (>= 0)	Las ventas no pueden ser negativas. Eran residuos numéricos de la estimación global.
`entity`	Mezcla de países y bloques	Generación de bandera `tipo_entidad`	Evita la doble contabilización en agregaciones nacionales frente a métricas mundiales.

3. Transformaciones Aplicadas

Con el objetivo de preparar el dataset para los modelos analíticos y proyecciones del Avance 3, el pipeline ejecuta las siguientes transformaciones:

- **Estandarización de Encabezados:** Conversión de nombres de columnas a formato uniforme (`entity`, `code`, `year`, `electric_cars_sold`).
- **Casting Explícito de Tipos:** Conversión estricta de la variable `electric_cars_sold` a tipo numérico entero (`int64`).
- **Segmentación por Alcance:** Creación de la variable categórica `tipo_entidad` para diferenciar entre 'País' y 'Agregado'.
- **Categorización por Nivel de Adopción:** Clasificación ordinal de volumen de ventas mediante cuantiles (`nivel_adopcion`: Bajo, Medio, Alto).

> **Integración de China:** El dataset procesado abarca el período 2010–2025 para un total de 60 países, incluyendo explícitamente a **China** con 954 registros analíticos limpios y listos para modelar.

4. Matriz Comparativa (Antes vs. Después)

Métrica / Estado	Dataset Original (Raw)	Dataset Procesado (dataset_limpio.csv)
Total de Filas	823	819 (filtradas anomalías negativas)
Número de Columnas	4	6 (incluye `tipo_entidad` y `nivel_adopcion`)
Valores Nulos en Código	16	0 (imputados con DESC)
Valores Negativos en Ventas	4	0
Integridad para Modelado	Requiere tratamiento previo	100% Validado por assert de pipeline